

Earthquake Application

Relazione del progetto

Nicola Modugno - mat. 0001176883

A.A. 2024-25

1 INTRODUZIONE E DEFINIZIONE DEL PROBLEMA

Il presente lavoro implementa in Apache Spark un sistema per l'identificazione di co-occorrenze sismiche su un dataset di 3.4 milioni di eventi registrati nel periodo compreso tra il 1990-01-01 ed il 2023-07-29

1.1 DEFINIZIONE DI CO-OCCORRENZA

Due località geografiche *co-occorrono* quando si verificano eventi sismici in entrambe le località nello stesso giorno ma in celle geografiche distinte. L'obiettivo è identificare la coppia di località con il massimo numero di giornate in cui entrambe registrano attività sismica.

1.2 PREPROCESSING DEI DATI

Il preprocessing costituisce una fase importante per la correttezza dell'analisi e si articola in tre fasi principali. La prima fase riguarda la discretizzazione spaziale: le coordinate geografiche vengono arrotondate alla prima cifra decimale con `RoundingMode.DOWN`. Questo non è un arrotondamento matematico standard, ma un troncamento delle cifre decimali, ed è essenziale implementarlo in questa modalità affinché il risultato finale sia corretto:

```
def roundCoordinate(coord: Double): Double = {
    BigDecimal(coord).setScale(1, RoundingMode.DOWN).toDouble
}
```

Ad esempio, la coppia di coordinate (37.547, 15.399) viene trasformata in (37.5, 15.3) e non in (37.5, 15.4) come avverrebbe con un arrotondamento matematico tradizionale.

La seconda fase riguarda la discretizzazione temporale: i timestamp vengono normalizzati estraendo solo la data nel formato YYYY-MM-DD, definendo così una finestra temporale giornaliera e rimuovendo l'informazione oraria. Infine, la terza fase consiste nella rimozione dei duplicati. Eventi multipli nella stessa cella geografica e nello stesso giorno vengono considerati come un singolo evento. Questa fase è essenziale per evitare che la coppia con massime co-occorrenze corrisponda alla stessa località.

Applicando queste trasformazioni al dataset originale di **3,445,751** eventi si ottengono **2,198,460** eventi unici, corrispondenti a celle geografiche uniche per giornata.

2 APPROCCI IMPLEMENTATI

Sono stati implementati tre approcci basati su diverse primitive di Apache Spark per valutare trade-off tra semplicità implementativa, utilizzo di memoria e performance.

2.1 APPROCCIO 1: GROUPBYKEY

La strategia più diretta utilizza groupByKey per aggregare località per data:

```
val eventsByDate = uniqueEvents
    .map { case (location, date) => (date, location) }
    .repartition(numPartitions)

val locationsByDate = eventsByDate.groupByKey()

val coOccurrences = locationsByDate.flatMap {
    case (date, locations) =>
        val locList = locations.toList.sorted
        for {
            i <- locList.indices
            j <- (i + 1) until locList.length
        } yield (LocationPair(locList(i), locList(j)), date)
}
```

Questa soluzione richiede lo shuffle completo di tutte le località per ogni data e la materializzazione in memoria delle liste di località per data può essere onerosa per giornate con molti eventi.

2.2 APPROCCIO 2: AGGREGATEBYKEY

Il secondo approccio utilizza aggregazione incrementale tramite Set per ridurre il volume di dati trasferiti:

```
val locationsByDate = eventsByDate
    .aggregateByKey(Set.empty[Location])(
        (set, loc) => set + loc,           // combiner
        (set1, set2) => set1 ++ set2    // merger
    )
```

In questo caso l'aggregazione locale (map-side) riduce significativamente la quantità di dati nello shuffle, mentre la struttura Set elimina automaticamente eventuali duplicati rimanenti.

2.3 APPROCCIO 3: REDUCEBYKEY

Infine, l'approccio più ottimizzato sfrutta reduceByKey per la rimozione dei duplicati:

```
val uniqueEvents = normalizedEvents
  .map { case (lat, lon, date) =>
    ((Location(lat, lon), date), 1)
  }
  .reduceByKey(_ + _) // deduplicazione distribuita
  .map { case ((location, date), _) => (location, date) }
```

Questa riduzione distribuita a due livelli (map-side e reduce-side) minimizza shuffle e memoria, risultando particolarmente efficiente su dataset con alta cardinalità di chiavi.

2.4 CONTEGGIO CO-OCCORRENZE

Tutti gli approcci convergono nella fase finale di conteggio:

```
val pairCounts = coOccurrences
  .map { case (pair, _) => (pair, 1) }
  .reduceByKey(_ + _)

val maxPair = pairCounts.reduce((a, b) =>
  if (a._2 > b._2) a else b
)
```

Il risultato finale include la coppia vincente e l'array di date ordinate in cui co-occorre.

3 SETUP SPERIMENTALE

3.1 INFRASTRUTTURA CLOUD

Gli esperimenti sono stati condotti su Google Cloud Dataproc con configurazioni hardware omogenee:

Tabella 3.1: Configurazioni Cluster Testate

| Config | Workers | vCPU Tot. | RAM Tot. | Partizioni |
|---------------|----------------|------------------|-----------------|-------------------|
| 2W | 2 | 12 | 48 GB | 8, 16, 32 |
| 3W | 3 | 16 | 64 GB | 12, 24, 36 |
| 4W | 4 | 20 | 80 GB | 16, 32, 48 |

Tutte le macchine (master e worker) utilizzano tipo n2-standard-4 (4 vCPU, 16 GB RAM) come specificato dai requisiti di progetto. Le configurazioni Spark sono: executor memory 10GB, driver memory 6GB, con overhead di 2GB e 1GB rispettivamente.

3.2 PARTIZIONAMENTO

Tutti gli approcci utilizzano **Hash Partitioning** tramite il metodo `repartition(n)` per distribuire uniformemente i dati. Sono state testate configurazioni seguendo la regola empirica di $1 - 6 \times$ il numero di vCPU disponibili per identificare la zona ottimale.

3.3 METRICHE RACCOLTE

Il sistema genera automaticamente metriche dettagliate per ogni esecuzione. In particolare vengono raccolti i seguenti dati: `total_events` rappresenta il numero di eventi caricati dal CSV (3,445,751); `unique_events` indica gli eventi dopo la fase di deduplicazione (2,198,460); `co_occurrences` conta le tuple (`LocationPair`, `date`) generate dal processo (225,085,862); `max_count` rappresenta il numero di giorni in cui la coppia vincente co-occorre (10,837). Vengono inoltre registrati i tempi di caricamento, analisi e totale, tutti espressi in millisecondi.

4 RISULTATI SPERIMENTALI

4.1 PERFORMANCE COMPARATIVA

La Tabella 4.1 riporta i tempi di analisi (in secondi) per diverse configurazioni:

Tabella 4.1: Tempi di Analisi per Configurazione (secondi)

| Config | GroupByKey | AggregateByKey | ReduceByKey |
|--------|--------------|----------------|--------------|
| 2W-8p | 882.8 | 837.8 | 992.2 |
| 2W-16p | 832.3 | 772.6 | 748.8 |
| 2W-32p | 714.6 | 724.8 | 747.9 |
| 3W-12p | 554.5 | 547.2 | 538.5 |
| 3W-24p | 455.6 | 492.8 | 488.5 |
| 3W-36p | 444.5 | 444.0 | 435.3 |
| 4W-16p | 403.1 | 432.2 | 442.0 |
| 4W-32p | 424.8 | 399.6 | 387.3 |
| 4W-48p | 329.4 | 342.5 | 329.4 |

Dall'analisi della tabella emerge che `ReduceByKey` risulta il più veloce su configurazioni ottimali (2W-16p, 4W-32p, 4W-48p), mentre `GroupByKey` si dimostra competitivo su cluster grandi con molte partizioni, eguagliando i tempi di esecuzione dell'approccio che implementa `ReduceByKey` nella configurazione 4W-48p. `AggregateByKey`, invece, offre performance consistenti ma generalmente inferiori rispetto agli altri due approcci.

4.2 IMPATTO DEL PARTIZIONAMENTO

Il numero di partizioni influenza significativamente le performance. La Figura 4.1 mostra l'effetto per l'approccio GroupByKey:

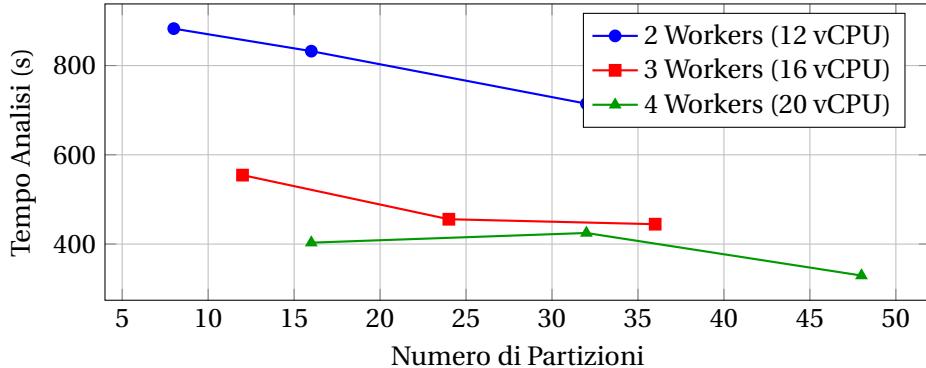


Figura 4.1: Impatto Numero Partizioni su GroupByKey

Dalla figura si evince l'esistenza di tre zone di performance distinte. Quando il numero di partizioni è inferiore a $2 \times$ il numero di vCPU (sottopartizionamento), si verifica una sottoutilizzazione della CPU con un incremento dei tempi del 20-24%. La zona ottimale si colloca tra $2 \times$ e $4 \times$ il numero di vCPU, dove si raggiunge il massimo parallelismo e i tempi minimi. Infine, quando si superano $4 \times$ vCPU (sovrapartizionamento), l'overhead di scheduling diventa apprezzabile e le performance degradano leggermente.

4.3 SCALABILITÀ

L'analisi di strong scaling con partizioni ottimali (circa $2 - 3 \times$ vCPU) rivela risultati interessanti:

Tabella 4.2: Analisi Scalabilità Workers

| Approccio | 2W (s) | 3W (s) | 4W (s) | Speedup |
|----------------|--------|--------|--------|---------------|
| GroupByKey | 714.6 | 444.5 | 329.4 | 2.17 \times |
| AggregateByKey | 724.8 | 444.0 | 342.5 | 2.12 \times |
| ReduceByKey | 747.9 | 435.3 | 329.4 | 2.27 \times |

Lo speedup $S = T_{2w} / T_{4w}$ mostra eccellente scalabilità. Calcolando l'efficienza come mostrato nell'Equazione 4.1, si osserva un comportamento super-lineare:

$$\text{Efficiency} = \frac{S}{n/2} = \frac{2.17}{2} = 1.08 \text{ (108\%)} \quad (4.1)$$

Questo fenomeno può essere attribuito a tre fattori principali: il migliore utilizzo della cache dovuto a partizioni più piccole per worker, la riduzione della latency nell'aggregazione locale, e un migliore bilanciamento del carico su cluster più grandi.

5 DISCUSSIONE

5.1 INTERPRETAZIONE DEI RISULTATI

I risultati confermano che la scelta dell'approccio e del partizionamento ha impatto significativo sulle performance. ReduceByKey risulta vincente in quanto minimizza lo shuffle attraverso la combinazione locale pre-shuffle, riduce l'utilizzo di memoria evitando la materializzazione di collezioni intermedie, e scala meglio all'aumentare della cardinalità delle chiavi.

AggregateByKey offre un buon compromesso tra flessibilità e performance, mantenendo un comportamento prevedibile su diverse configurazioni ed risultando particolarmente adatto quando serve un'aggregazione personalizzata (ad esempio con strutture dati come Set o Map).

GroupByKey rimane competitivo quando il cluster dispone di RAM abbondante, il numero di località per data è moderato, e la semplicità del codice è prioritaria rispetto all'ottimizzazione estrema delle performance.

5.2 CONFIGURAZIONE OTTIMALE IDENTIFICATA

Per il dataset analizzato (3.4M eventi, 225M tuple intermediate), la configurazione ottimale identificata prevede l'utilizzo di un cluster con 4 workers di tipo n2-standard-4, per un totale di 20 vCPU. Il numero di partizioni ottimale è 48, corrispondente a un ratio di 2.4 volte il numero di vCPU. L'approccio raccomandato è ReduceByKey o GroupByKey, che su questa configurazione offrono performance equivalenti con un tempo di esecuzione di 329 secondi (5.5 minuti).

6 CONCLUSIONI

Questo lavoro ha presentato un'analisi comparativa di tre strategie per l'identificazione di co-occorrenze sismiche distribuite in Apache Spark. I risultati sperimentali hanno evidenziato tre aspetti fondamentali.

In primo luogo, la scelta dell'approccio si rivela critica: ReduceByKey offre fino al 33% di miglioramento rispetto a GroupByKey con sottopartizionamento (748s contro 992s sulla configurazione 2W-16p).

In secondo luogo, il partizionamento domina le performance complessive: una configurazione ottimale (2-4 volte il numero di vCPU) riduce il tempo fino al 63% rispetto a un sottopartizionamento (329s contro 883s sulla configurazione 4W).

Infine, la scalabilità si dimostra eccellente: è stato osservato uno speedup super-lineare di 2.27 volte tra 2 e 4 workers, indicando un'efficienza di parallelizzazione del 113%.

L'implementazione completa, inclusi gli script di deployment e il sistema di raccolta metriche, è disponibile nel repository del progetto: <https://github.com/nicola-modugno/EarthquakeApplication-SCP/>.